

BÁO CÁO THỰC HÀNH: TỐI ƯU HÓA MẠNG CNN TRÊN TẬP DỮ LIỆU MNIST

Họ Và Tên: Bùi Quốc Việt

Mã SSV: BIT240250

Môn Học: Học máy & khai phá dữ liệu

Giảng Viên: [TS. Hoàng Tiểu Bình](#)

I. ĐẶT VẤN ĐỀ VÀ MỤC TIÊU THÍ NGHIỆM

Trong khai phá dữ liệu hình ảnh, mạng nơ-ron tích chập (CNN) là một kiến trúc mạnh mẽ. Tuy nhiên, hiệu năng của mô hình phụ thuộc rất lớn vào việc lựa chọn thuật toán tối ưu hóa (Optimizer) và các kỹ thuật điều chuẩn nhằm chống hiện tượng quá khớp (Overfitting).

Thí nghiệm này được thiết lập nhằm mục đích khai phá và so sánh hiệu năng trực quan giữa 5 cấu hình mạng CNN khác nhau dựa trên việc thay đổi thuật toán tối ưu (SGD, SGD + Momentum, Adam), kỹ thuật chuẩn hóa lớp (Batch Normalization), và kỹ thuật tắt nơ-ron ngẫu nhiên (Dropout).

II. THIẾT LẬP HỆ THỐNG VÀ THU THẬP DỮ LIỆU

- Tập dữ liệu:** Sử dụng tập dữ liệu chuẩn MNIST (chữ số viết tay từ 0 đến 9). Tập huấn luyện được áp dụng các bộ tiền xử lý tăng cường (RandomCrop, RandomHorizontalFlip, Normalize).
- Kiến trúc mạng tích chập:** Sử dụng chung một khung cấu trúc CNN gồm các khối Conv Block (Conv2d $\rightarrow$

BatchNorm2d $\rightarrow$ ReLU $\rightarrow$ MaxPool2d).
Mô hình linh hoạt bật/tắt lớp **Batch Normalization** và thay đổi hệ số lớp **Dropout** tùy theo từng cấu hình thí nghiệm.

3. Các cấu hình kiểm thử:

- **B1_Basic_SGD**: Mô hình cơ bản dùng SGD truyền thống, không áp dụng Batch Normalization (BN) hay Dropout (DO).
- **B2_BN_DO02_SGDM**: Có BN, DO = 0.2, sử dụng SGD kết hợp Momentum.
- **B2_BN_DO05_SGDM**: Có BN, DO = 0.5, sử dụng SGD kết hợp Momentum.
- **B2_BN_DO02_Adam**: Có BN, DO = 0.2, sử dụng thuật toán tối ưu Adam.
- **B2_BN_DO05_Adam**: Có BN, DO = 0.5, sử dụng thuật toán tối ưu Adam.

III. KẾT QUẢ KHAI PHÁ DỮ LIỆU TỔNG HỢP (**mnist_optimization_results.csv**)

Sau khi thực thi huấn luyện qua 4 Epoch cố định, dữ liệu kết quả cuối cùng thu được và sắp xếp theo thứ tự Độ chính xác kiểm định (Validation Accuracy) giảm dần như sau:


Thứ hạng	Tên cấu hình (Experiment)	Thuật toán tối ưu (Optimizer)	Chuẩn hóa lớp (Batch Norm)	Tỷ lệ Dropout	Hàm mất mát cuối (Final Train Loss)	Độ chính xác tốt nhất (Best Val Acc)	Thời gian chạy (Train Time)	Epoch đạt ngưỡng hội tụ
1	B2_BN_DO02_Adam	Adam	Có	0.2	0.1370	96.50%	15.4 giây	4
2	B2_BN_DO02_SGDM	SGD + Momentum	Có	0.2	0.1559	95.15%	15.5 giây	4
3	B2_BN_DO05_Adam	Adam	Có	0.5	0.1725	92.85%	15.2 giây	2
4	B2_BN_DO05_SGDM	SGD + Momentum	Có	0.5	0.1949	92.60%	15.0 giây	2
5	B1_Basic_SGD	SGD	Không	0.0	2.3022	10.65%	19.7 giây	1

IV. PHÂN TÍCH DIỄN BIẾN TIẾN TRÌNH HỌC TẬP (mnist_training_history.csv)

Dựa trên bảng ghi lịch sử chi tiết từng epoch, chúng ta phát hiện ra các quy luật học tập cốt lõi của mạng nơ-ron:

- **Hiện tượng triệt tiêu Gradient:** Cấu hình **B1_Basic_SGD** bắt đầu với mức loss rất cao (2.3031) và kết thúc epoch 4 gần như không thay đổi (2.3022). Độ chính xác bị khóa chặt ở mức 10.65%. Điều này chứng tỏ việc thiếu đi **Batch Normalization** trên mạng sâu khiến gradient bị triệt tiêu hoàn toàn, mô hình không thể học.
- **Ưu thế bứt phá giai đoạn đầu của Adam:** Ở Epoch 1, cấu hình **B2_BN_DO02_Adam** đạt mức loss là 0.8693, tối ưu vượt trội hơn so với **B2_BN_DO02_SGDM** (mức loss 0.9929). Cho thấy Adam tự động điều chỉnh tốc độ học (learning rate) thông minh giúp mô hình bắt nhịp nhanh ở giai đoạn đầu.

V. PHÂN TÍCH ĐỒ THỊ TRỰC QUAN



Hình ảnh đồ thị từ quá trình phân tích thực tế cung cấp cái nhìn rõ nét nhất về hành vi tối ưu hóa:

1. Đồ thị Training Loss (Trái):

- Đường thẳng màu xanh dương nằm cô đọng ở trên cùng đại diện cho mô hình học thất bại **B1_Basic_SGD**.

- Bốn đường cong còn lại biểu diễn cho nhóm cấu hình có **Batch Normalization** sở hữu chung một hình thái dốc xuống hoàn hảo. Đặc biệt từ Epoch 1 đến Epoch 2, độ dốc cực lớn chứng tỏ mô hình khai phá dữ liệu rất mạnh mẽ trước khi phẳng dần và hội tụ ổn định từ Epoch 3 đến Epoch 4.

2. Đồ thị Validation Accuracy (Phải):

- Trong khi đường xanh dương chìm sâu dưới đáy (10.65%), nhóm có BN đồng loạt vọt lên trên ngưỡng 80% ngay từ bước chạy đầu tiên.
- **Đường màu cam (B2_BN_DO02_Adam):** Tăng tiến ổn định và bền vững, dẫn đầu cuộc đua hiệu năng và cán đích ở vị trí cao nhất (96.50%).
- **Đường màu tím (B2_BN_DO05_SGDM):** Thể hiện rõ sự bất ổn của kỹ thuật điều chuẩn quá đà. Đồ thị tăng lên và đạt đỉnh ở Epoch 2, đi ngang ở Epoch 3 nhưng đến Epoch 4 **bị uốn cong gấp xuống** đáng kể. Điều này chứng tỏ tỷ lệ Dropout quá cao (0.5) vô tình triệt tiêu quá nhiều nơ-ron hữu ích, làm nhiễu loạn và suy giảm khả năng tổng quát hóa dữ liệu ở các vòng lặp cuối.

VI. KẾT LUẬN VÀ KIẾN NGHỊ

Từ các kết quả khai phá định lượng và định tính thu được từ hệ thống thí nghiệm, bài báo cáo đưa ra các kết luận khoa học sau:

1. **Cấu hình tối ưu nhất:** Mô hình xây dựng dựa trên thuật toán tối ưu **Adam**, kết hợp kỹ thuật **Batch Normalization** và đặt **Dropout ở mức vừa phải (0.2)** mang lại hiệu năng khai phá cao nhất (Độ chính xác 96.50%).
2. **Vai trò cốt lõi của Batch Normalization:** Kỹ thuật này đóng vai trò quyết định, giúp phân phối chuẩn lại đầu vào của mỗi lớp, ngăn chặn hiện tượng triệt tiêu gradient và cho phép mô hình hội tụ thành công.

3. **Bài học về điều chuẩn (Regularization):** Kỹ thuật Dropout rất tốt để chống hiện tượng học tủ (overfitting), tuy nhiên không nên lạm dụng ở mức quá cao (0.5) vì nó sẽ gây mất mát thông tin hữu ích và làm đồ thị học tập bị trôi sụt ở giai đoạn cuối.